

Modèles génératifs à diffusion

T.Gipteau, A.Gonin, M.Mahamat

6 janvier 2025

Résumé

Depuis quelques années, les modèles génératifs se sont énormément développés dans les méthodes de machine learning. Le principe de ces modèles est le suivant : à partir d'un jeu de données (par exemple, un ensemble d'images), un modèle génératif a pour objectif de générer de nouvelles données qui ressemblent aux données initiales. Dans un langage plus mathématique, l'objectif est d'être capable de simuler une approximation de la distribution sous-jacente aux données d'apprentissage. Plusieurs types de méthodes souvent basées sur les réseaux de neurones sont aujourd'hui disponibles pour réaliser efficacement ce type d'objectif. Parmi elles, on trouve les GAN (Generative Adversarial Models), les auto-encodeurs et les méthodes basées sur la simulation de processus de diffusions. L'objectif de ce projet est de se focaliser sur les méthodes de diffusions qui semblent gagner en importance depuis quelques années. Il s'agira dans un premier temps d'en comprendre l'implémentation puis les fondements théoriques (et notamment la notion d'inversion du temps pour des diffusions). Dans un second temps, on tentera de reproduire une ou plusieurs des applications proposées dans la littérature pour le débruitage ou la génération de données. Enfin, on tentera de proposer une alternative originale : développement de la méthode sur un problème numérique original ou mise en œuvre de la méthode sur un modèle non standard (équations cinétiques). . .

1 Principe général

Nous avons déjà mentionné que le principe général des modèles génératifs est d'apprendre à produire, à partir de données initiales, de nouvelles données similaires. Les modèles à diffusions sont un cas particulier de ce principe : en définissant un processus de "bruitage pas-à-pas" des données initiales dont on connaît la nature "inversible" ainsi que la "limite", on peut, à partir de cette distribution limite simulable, "débruiter pas-à-pas" jusqu'à obtenir une nouvelle donnée vraisemblable dans l'espace des données initiales. Dans la plus grande partie de cet article, on considérera le cadre facilitant de la génération d'images, et particulièrement du dataset MNIST. Commençons par définir les processus de diffusions, et leur utilité dans notre cadre pratique.

1.1 Processus de diffusion

Un processus de diffusion est un processus stochastique, définit sous sa forme générale *forward* par [2] :

$$\begin{cases} dX_t = f(X_t, t)dt + g(t)dW_t \\ X_0 \sim p_0 \end{cases}$$

où dW_t est une marche aléatoire de loi normale centrée réduite (mouvement brownien). On notera toujours dans la suite p_t pour désigner la loi de X_t à un instant t du processus donné.

Un tel processus doit être compris, dans notre cas "MNIST", comme le modèle théorique (*i.e.* continu) d'un bruitage des images de départ, où p_0 désigne la distribution des images de départ pixel par pixel. Une version discrétisée est alors donnée par :

$$\begin{cases} X_{k+1} = X_k + \Delta_t f(X_k, k\Delta_t) + g(k\Delta_t)\sqrt{k\Delta_t}Z_k \\ Z_k \sim \mathcal{N}(0, 1) \\ X_0 \in dataset \end{cases}$$


avec Δ_t suffisamment petit.

D'après le théorème d'Anderson [1], on sait qu'un tel processus est inversible, au sens où on a le processus de diffusion à temps inversé *reverse* suivant :

$$\begin{cases} d\hat{X}_t = [f(\hat{X}_t, t) - g(t)^2 \nabla_x \log p_t(\hat{X}_t)] dt + g(t) d\hat{W}_t \\ X_T \sim p_T \end{cases}$$

Par un schéma discrétisé similaire à celui du processus *forward*, on devrait alors pouvoir, à partir d'une image bruitée (X_T), générer une image restaurée (X_0) correspondant à l'état initial, *i.e.* avant bruitage par le processus de diffusion *forward*. En admettant qu'on prenne un T suffisamment grand, on peut supposer que X_T sera entièrement constituée de bruit, et donc potentiellement facilement simulable.

FIGURE 1 – Le modèle forward-reverse sur une image [4]



Deux problèmes sont soulevés par ce modèle :

- Bien que simuler le processus *forward* soit facile à partir d'un échantillon de p_0 , ce n'est pas le cas pour le processus *reverse* : la loi p_t n'est pas connue a priori, et à plus forte raison le terme $\nabla_x \log p_t(\hat{X}_t)$
- Pour la même raison, nous ne pouvons pas simuler X_T , car la loi limite du processus reste inconnue.

Ces deux problèmes seront résolus de manières différentes, que nous verrons par la suite. On se concentrera d'abord sur l'idée générale permettant l'approximation du terme $\nabla_x \log p_t(\hat{X}_t)$.

1.2 Approximation et fonction de score

Une méthode adaptée pour déterminer le terme $\nabla_x \log p_t(\hat{X}_t)$ est de construire un réseau de neurone destiné à l'approximer. Considérons dans un premier temps l'interprétation de ce terme. Nous nous dégageons de la notion "itérative" des modèles de diffusion dans cette section, et y reviendrons par la suite.

Nous cherchons à estimer une distribution de probabilité, à une étape donnée du processus. Dans ce cadre, la probabilité recherchée sera notée $p(x)$. Par une estimation à travers un réseau de neurone, une telle distribution est estimée par $p(x) \approx f(x)/Z$, où f désigne la sortie du réseau, et Z désigne une constante de normalisation.

Dans les faits, une telle constante est compliquée à calculer, et la plupart des méthodes précédentes visaient à approximer cette constante à moindre coût. Dans le cadre des modèles à diffusion, cette constante est contournée par l'utilisation du *score de Stein* $\nabla_x \log p(x)$:

$$\nabla_x \log p(x) = \nabla_x f(x) - \nabla_x Z$$

FIGURE 2 – Distribution des données initiales [3]




Dans ce cas, le terme dépendant de Z disparaît, cependant que par des calculs d'intégrales, ces fonctions $p(x)$ et $\nabla_x \log p(x)$ sont équivalentes. Cette équivalence est visuellement expliquée par la figure 3.

La disparition du besoin de normalisation permet une estimation efficace par réseau de neurone. Notre réseau sera ainsi chargé d'estimer un *champs de vecteurs*, le plus proche possible du score de Stein. Cette proximité se traduit par la divergence de Fisher, définie par :

$$\frac{1}{2} \mathbf{E}_p[\|s_\theta(x) - \nabla_x \log p(x)\|^2]$$

Maintenant que nous avons à notre disposition une fonction désignant la distance entre notre réseau et le terme problématique, deux chemins s'offrent à nous. Le premier, nommé "Denoising Score Matching", est l'objet de la section suivante. Une autre section s'intéressera à l'approche "Sliced Score Matching".

FIGURE 3 – Distribution et score de Stein [3]



2 Denoising score matching

Retournons au cadre itératif du modèle de diffusion, dans lequel il s'agit d'estimer $\nabla_x \log p_t(\hat{X}_t)$. A partir du score de Fisher, nous pouvons définir le score d'un réseau qui chercherait à estimer ce terme en fonction du temps t du processus, comme une intégrale sur l'intervalle de temps des scores de Fisher. Nous définissons donc la perte suivante :

$$\mathcal{L}_{DSM} = \int_0^T \lambda(t) \mathbf{E}_{X_t} [\|s_\theta(X_t, t) - \nabla_{X_t} \log p_t(X_t)\|^2]$$

où $\lambda(t)$ est un facteur de poids positif, optionnel.

Quoi qu'il en soit, les deux problèmes soulevés dans la première sections ne sont toujours pas résolus, la difficulté se résumant dans le fait de ne pas connaître la loi p_t pour t donné.

Dans le cadre DSM, le problème est contourné en deux temps. Premièrement, nous choisirons un processus de diffusion précis qui, sans être de loi de transition p_t connue, possède une expression explicite des lois de transitions conditionnellement à X_0 . Deuxièmement, une réécriture de la fonction de perte $\mathcal{L}_{DSM}$ permettra d'employer ces lois conditionnelles, jusqu'à un cadre applicable en pratique.

2.1 Le processus Ornstein-Uhlenbeck

Un processus d'Ornstein-Uhlenbeck est un processus de la forme :

$$dX_t = -\beta X_t dt + \sigma dW_t$$

Ce processus vérifie :

$$\begin{cases} p_{t|0} = \mathcal{N}(e^{-\beta t} X_0, \sigma_t^2 I) \\ \sigma_t^2 = \frac{\sigma^2}{2\beta} (1 - e^{-2\beta t}) \end{cases}$$

On peut déduire de ces propriétés une résolution du problème concernant l'ignorance de la loi limite du processus de diffusion. En effet, on a :

$$p_{t|0} \xrightarrow{t \rightarrow \infty} \mathcal{N}(0, \frac{\sigma^2}{2\beta})$$

loi limite indépendante de l'état initial. On a donc une loi ($\sim X_T$ pour T grand) facilement simulable, permettant de donner un point de départ au processus *reverse* visant à générer des images.

Nous notons alors que le processus Ornstein-Uhlenbeck peut se réécrire (notations conservées par la suite) :

$$\begin{cases} X_t = \gamma_t X_0 + \sigma_t \varepsilon \\ \gamma_t = e^{-\beta t} \\ \varepsilon \sim \mathcal{N}(0, I) \end{cases}$$

2.2 Réécriture de $\mathcal{L}_{DSM}$

2.3 DDPM et choix d'architecture du réseau

Références

- [1] Brian D.O. ANDERSON. “Reverse-time diffusion equation models”. In : *Stochastic Processes and their Applications* 12.3 (1982), p. 313-326. ISSN : 0304-4149. DOI : [https://doi.org/10.1016/0304-4149\(82\)90051-5](https://doi.org/10.1016/0304-4149(82)90051-5). URL : <https://www.sciencedirect.com/science/article/pii/0304414982900515>.
- [2] Ernest RYU. *Generative AI and Foundation Models, Spring 2024*. URL : <https://ernestryu.com/courses/FM.html>. Chapitres 1, 2 et 3.
- [3] Yang SONG. *Diffusion and Score-Based Generative Models*. URL : <https://www.youtube.com/watch?v=wMmqCMwuM2Q>.
- [4] Yang SONG et al. *Score-Based Generative Modeling through Stochastic Differential Equations*. 2021. arXiv : 2011.13456 [cs.LG]. URL : <https://arxiv.org/abs/2011.13456>.